

MVP: Construção de um Pipeline de Dados na Nuvem

Análise Histórica do Comércio Exterior Brasileiro.

Guillermo da Rosa Lipke Enseñat

Trabalho prático apresentado como requisito para o cumprimento das obrigações da disciplina de Engenharia de Dados.

Rio de Janeiro, 26 de Outubro de 2026

1. Contexto de Negócios e Perguntas

1.1 Problema

Ao longo das últimas três décadas, a dinâmica do comércio exterior brasileiro passou por transformações profundas impulsionadas pela globalização, acordos comerciais, flutuações cambiais e pela ascensão de novos *players* globais na cadeia de suprimentos (com destaque para a China). No entanto, compreender de forma granular como essas mudanças reconfiguraram a dependência externa do Brasil por setor de produto e país de origem exige o cruzamento de um volume massivo de dados históricos. Sem uma engenharia de dados estruturada, é difícil mapear quais nações ganharam ou perderam espaço relativo no fornecimento de bens para o mercado brasileiro ao longo de quase 30 anos.

1.2 Objetivo

Desenvolver um pipeline de engenharia de dados utilizando a arquitetura Lakehouse (Medallion) no Databricks, **processando a série histórica completa das bases de importação do Comex Stat (MDIC) de 1997 até os dias atuais**. O objetivo é estruturar um modelo analítico capaz de **calcular a evolução do *market share*** dos países parceiros e o perfil de valor das importações brasileiras desagregadas por setor e códigos NCM, **identificando tendências de concentração ou diversificação de mercado ao longo de quase três décadas**.

1.3 Perguntas de Negócio

Para guiar a modelagem dos dados e a extração de *insights*, o projeto busca responder às seguintes questões:

1. Quais países mais ganharam ou perderam espaço relativo (*market share* em Valor FOB) no fornecimento total de importações para o Brasil entre 1997 e o período recente?
2. Como essa realocação de parceiros comerciais se distribui por grandes setores da economia ou setores específicos de NCM (ex: eletrônicos, químicos, bens de capital)?
3. Quais classes de produtos (NCMs) apresentaram maior volatilidade ou mudança estrutural em sua origem de importação ao longo desses quase 30 anos?


1.4 Fontes dos Dados e Licença

- **Fonte:** Comex Stat (Ministério do Desenvolvimento, Indústria, Comércio e Serviços - MDIC). A base inclui códigos NCM, países de origem (CO_PAIS), valores em Dólares FOB (VL_FOB) e pesos líquidos.
- [Estatísticas de Comércio Exterior em Dados Abertos — Ministério do Desenvolvimento, Indústria, Comércio e Serviços](#)
- **Licença:** Dados disponibilizados pelo Governo Federal brasileiro em plataformas abertas (compatível com a Política de Dados Abertos do Governo Federal), permitindo livre processamento, engenharia e publicação técnica.

2. Carga dos Dados (Upload e Staging)

Antes de iniciar o tratamento na arquitetura Lakehouse, foi necessário orquestrar a extração e o carregamento seguro dos dados originais para a nuvem. Esta etapa inicial (configurada no notebook MVP02_Download) atua como a área de *Staging* do projeto.

- **Processo:** Os 30 ficheiros anuais em formato CSV (representando a série histórica de importações de 1997 a 2026) foram descarregados diretamente da plataforma de Dados Abertos do MDIC.
- **Armazenamento em Nuvem:** Em vez de manter os dados locais, eles foram carregados de forma centralizada e segura no ambiente do Databricks, utilizando o recurso de **Volumes do Unity Catalog**. O diretório criado para receber esta carga bruta foi o `/Volumes/mvp/staging/mdic`.
- **Objetivo da Camada:** Garantir que o motor de processamento distribuído (Apache Spark) tenha acesso rápido, direto e escalável aos dados brutos sem depender de sistemas externos durante as etapas seguintes de ETL.
- Criação do Volume:




```
Yesterday (2s) 1
%sql
USE CATALOG mvp;
USE SCHEMA staging;
> See performance \(2\)

OK
This result is stored as _sqlidf and can be used in other Python and SQL cells.

Yesterday (1s) 2
%sql
CREATE VOLUME MDIC
> See performance \(1\)
```

- *Evidência do Upload dos ficheiros (30 anos de dados):*




Name	Size	Last modified
IMP_1997.csv	65.55 MB	7 minutes ago
IMP_1998.csv	69.48 MB	7 minutes ago
IMP_1999.csv	62.23 MB	7 minutes ago
IMP_2000.csv	68.64 MB	7 minutes ago
IMP_2001.csv	69.61 MB	7 minutes ago
IMP_2002.csv	66.28 MB	7 minutes ago
IMP_2003.csv	66.41 MB	7 minutes ago
IMP_2004.csv	74.64 MB	6 minutes ago
IMP_2005.csv	79.33 MB	6 minutes ago
IMP_2006.csv	86.19 MB	6 minutes ago
IMP_2007.csv	93.82 MB	4 minutes ago
IMP_2008.csv	101.98 MB	4 minutes ago
IMP_2009.csv	97.82 MB	4 minutes ago
IMP_2010.csv	116.70 MB	4 minutes ago
IMP_2011.csv	124.87 MB	4 minutes ago
IMP_2012.csv	128.74 MB	4 minutes ago
IMP_2013.csv	132.90 MB	4 minutes ago
IMP_2014.csv	132.92 MB	4 minutes ago
IMP_2015.csv	124.72 MB	4 minutes ago

Upload summary: 30 files uploaded

- /Volumes/mvp/staging/mdic/IMP_2018.csv
- /Volumes/mvp/staging/mdic/IMP_2019.csv
- /Volumes/mvp/staging/mdic/IMP_2020.csv
- /Volumes/mvp/staging/mdic/IMP_2021.csv
- /Volumes/mvp/staging/mdic/IMP_2022.csv
- /Volumes/mvp/staging/mdic/IMP_2023.csv
- /Volumes/mvp/staging/mdic/IMP_2024.csv
- /Volumes/mvp/staging/mdic/IMP_2025.csv
- /Volumes/mvp/staging/mdic/IMP_2026.csv

3. Modelagem e Catálogo de Dados

O pipeline seguiu rigorosamente a **Arquitetura Medalhão** (Bronze, Silver e Gold) organizada dentro dos schemas do catálogo mvp



Schema	Table
mvp	bronze
bronze	Tables (1)
bronze	comex_importacao_total
gold	Tables (1)
gold	gold_market_share_setor_pais
information_schema	
silver	Tables (1)
silver	comex_importacao_limpa
staging	Volumes (1)
staging	mdic

3.1 Camada Bronze (Raw Data)

- **Descrição:** Persistência dos dados brutos num único grande espelho consolidado através da função `read_files()`.

```
%sql
USE CATALOG mvp;
USE SCHEMA bronze;

CREATE TABLE comex_importacao_total
USING delta
AS
SELECT *
FROM read_files ('/Volumes/mvp/staging/mdic/*.csv',
  format => 'csv',
  header => 'true',
  delimiter => ';',
  inferSchema => 'true')
```

- **Tabela:** `mvp.bronze.comex_importacao_total`

Yesterday (9s) 2 SQL

```
%sql
USE CATALOG mvp;
USE SCHEMA bronze;

SELECT COUNT(*) AS total_linhas FROM comex_importacao_total;

SELECT * FROM comex_importacao_total LIMIT 10;
```

See performance (3) ✓ Checked for improvements

	CO_ANO	CO_MES	CO_NCM	CO_UNID	CO_PAIS	SG_UF_NCM	CO_VIA	CO_URF	QT_ESTAT	KG_U
1	2010									
2	2010	3	48115129	10	628	SP	1	817800	23248	
3	2010	10	86072900	10	63	SP	1	817800	5168	
4	2010	6	84139190	10	399	SP	4	817700	622	
5	2010	11	39191000	10	249	SP	4	817700	2843	
6	2010	8	66019110	11	190	SP	1	817800	10	
7	2010	11	73269090	10	249	SP	1	817800	50951	
8	2010	10	84829990	10	275	SP	1	817800	14213	
9	2010	10	48115129	10	628	SP	1	817800	16193	
10	2010	4	30049078	10	69	SP	4	817600	38	

- Catálogo:



comex_importacao_total

OverviewSample DataDetailsPermissionsPoliciesHistoryLineageInsightsQuality

Description

The table contains data regarding total imports, including details such as year, month, product classification, quantities, weights, and various financial values related to imports. This data can be utilized for analyzing import trends, understanding trade dynamics, and assessing the overall performance of the import sector.

Filter columns...

Column	Type	Popularity	Comment	Tags	Column masking
CO_ANO	int		Year of the import transaction		
CO_MES	int		Month of the import transaction		
CO_NCM	int		Product classification code used for identifying specific types of imports.		
CO_UNID	int		Unit of measurement for the imported product, indicating how quantities are reported.		
CO_PAIS	int		Country code representing the origin of the imported goods.		
SG_UF_NCM	string		State or region code associated with the product classification for imports.		
CO_VIA	int		Indicates the mode of transportation used for importing goods.		
CO_URF	int		Unique reference code for the customs office processing the import transaction.	Add tags	Add column mask
QT_ESTAT	int		Quantity of products classified under a specific category that were imported.		
KG_LIQUIDO	int		Gross weight of the imported goods, providing insight into the overall volume of trade.		
VL_FOB	bigint		Value of goods at the point of shipment, excluding freight and insurance costs, crucial for calculating total import value.		
VL_FRETE	int		Freight cost associated with transporting the imported goods.		
VL_SEGURO	int		Insurance cost for the imported goods, essential for understanding additional import expenses.		
_rescued_data	string		Contains recovered or supplementary information that was rescued and added to the table, potentially for data integrity purposes.		

3.2 Camada Silver (Limpeza e Padronização)

- **Descrição:** Limpeza de campos nulos (WHERE VL_FOB > 0), correção de tipagem de campos numéricos (para DOUBLE) e formatação do NCM para 8 dígitos (LPAD)[cite: 8]. Adicionalmente, extraímos os dois primeiros dígitos do NCM para criar o atributo semântico fundamental para as análises: setor_capitulo

```
%sql
USE CATALOG.mvp;
USE SCHEMA silver;

CREATE OR REPLACE TABLE comex_importacao_limpa
USING delta
AS
SELECT
    CAST(CO_ANO AS INT) AS co_ano,
    CAST(CO_MES AS INT) AS co_mes,

    LPAD(CAST(CO_NCM AS STRING), 8, '0') AS co_ncm,

    SUBSTR(LPAD(CAST(CO_NCM AS STRING), 8, '0'), 1, 2) AS setor_capitulo,
    CAST(CO_PAIS AS INT) AS co_pais,
    UPPER(TRIM(SG_UF_NCM)) AS sg_uf_ncm,

    CAST(KG_LIQUIDO AS DOUBLE) AS kg_liquido,
    CAST(VL_FOB AS DOUBLE) AS vl_fob
FROM.mvp.bronze.comex_importacao_total
WHERE CO_ANO IS NOT NULL
    AND CO_PAIS IS NOT NULL
    AND VL_FOB > 0;
```

- **Tabela:**.mvp.silver.comex_importacao_limpa



Yesterday (8s)2

```
%sql
USE CATALOG mvp;
USE SCHEMA silver;

SELECT COUNT(*) AS total_linhas_silver FROM comex_importacao_limpa;

SELECT co_ano, co_ncm, setor_capitulo, co_pais, vl_fob, kg_liquido
FROM comex_importacao_limpa
LIMIT 10;
```

See performance (3)

Table +

	co_ano	co_ncm	setor_capitulo	co_pais	vl_fob	kg_liquido	
1	2017	85439090	85	386	1095	1	
2	2017	84133020	84	72	13073	37	
3	2017	84839000	84	195	453	14	
4	2017	85122022	85	246	12167	219	
5	2017	39269090	39	23	11220	108	
6	2017	85129000	85	361	12059	546	
7	2017	42023200	42	160	387288	26985	
8	2017	40093100	40	386	6071	573	
9	2017	39269090	39	160	5336	1501	
10	2017	84807100	84	351	92081	2839	

- Catálogo:

comex_importacao_limpa ☆

Open i

Overview Sample Data Details Permissions Policies History Lineage Insights Quality

Description

The table contains data related to import transactions for various commodities. It includes information on the year, month, commodity classification, country of origin, and metrics such as net weight and FOB value. This data can be used to analyze import trends, evaluate the financial implications of imports, and assess the impact on different sectors.

Filter columns...

Column	Type	Popularity	Comment	Tags	Column masking	
co_ano	int	...	Year of the import transaction			
co_mes	int	----	Month of the import transaction			
co_ncm	string	...	Commodity classification code used to categorize the type of imported goods.			
setor_capitulo	string	...	Classification category for commodities, grouping imports into specific sectors.			
co_pais	int	...	Country of origin for the imported commodities, indicating where the goods are sourced from.			
sg_uf_ncm	string	----	State or region code associated with the commodity classification, useful for identifying the geographical distribution of imports.			

kg_liquido	double	nil	Net weight of the imported commodities, measured in kilograms, providing insight into the volume of goods being imported.	Add tags	Add column mask	>
vl_fob	double	nil	Free on Board (FOB) value of the imported commodities, representing the cost of goods including transportation to the shipping point, essential for financial analysis of imports.			

3.3 Camada Gold (Business Aggregation)

- **Descrição:** Camada final modelada para responder diretamente ao problema de negócio. Nela, foi calculada a evolução percentual exata (market_share_perc) com base na divisão do valor FOB importado por um país num dado setor face ao valor FOB total desse mesmo setor.

```
Yesterday (7s) 1

%sql

USE CATALOG mvp;
USE SCHEMA gold;
CREATE OR REPLACE TABLE gold_market_share_setor_pais
USING delta
AS
WITH importacoes_por_setor_ano AS (
    SELECT
        co_ano,
        setor_capitulo,
        SUM(vl_fob) AS vl_fob_total_setor
    FROM mvp.silver.comex_importacao_limpa
    GROUP BY co_ano, setor_capitulo
),
importacoes_por_pais_setor_ano AS (
    SELECT
        co_ano,
        setor_capitulo,
        co_pais,
        SUM(vl_fob) AS vl_fob_pais_setor
    FROM mvp.silver.comex_importacao_limpa
    GROUP BY co_ano, setor_capitulo, co_pais
)
SELECT
    p.co_ano,
    p.setor_capitulo,
    p.co_pais,
    p.vl_fob_pais_setor,
    t.vl_fob_total_setor,

    ROUND((p.vl_fob_pais_setor / t.vl_fob_total_setor) * 100, 4) AS market_share_perc
FROM importacoes_por_pais_setor_ano p
JOIN importacoes_por_setor_ano t
    ON p.co_ano = t.co_ano
    AND p.setor_capitulo = t.setor_capitulo;
```

- **Tabela:** mvp.gold.gold_market_share_setor_pais
 - Tag “ORDER BY” mudando o ano se altera os dados – 2024 utilizado como amostra.

Yesterday (7s) 2

```
%sql
USE CATALOG mvp;
USE SCHEMA gold;

SELECT COUNT(*) AS total_linhas_gold FROM gold_market_share_setor_pais;

SELECT
  co_ano,
  setor_capitulo,
  co_pais,
  vl_fob_pais_setor,
  vl_fob_total_setor,
  market_share_perc
FROM gold_market_share_setor_pais
WHERE co_ano = 2024
ORDER BY market_share_perc DESC
LIMIT 10;
```

> [See performance \(3\)](#)

	1.3 co_ano	1.4 setor_capitulo	1.3 co_pais	1.2 vl_fob_pais_setor	1.2 vl_fob_total_setor	1.2 market_share_perc
1	2024	66	160	44426422	45728744	97.1521
2	2024	50	160	5038015	5207420	96.7469
3	2024	67	160	44742723	48088150	93.0431
4	2024	60	160	369204682	415795147	88.7949
5	2024	45	607	9491556	11020119	86.1293
6	2024	95	160	732638784	910326718	80.4809
7	2024	58	160	90781719	115231087	78.7823
8	2024	46	160	10441365	13899306	75.1215
9	2024	54	160	1148206459	1617524307	70.9854
10	2024	42	160	450936196	646097668	69.7938

- **Catálogo:**

gold_market_share_setor_pais

Overview | Sample Data | Details | Permissions | Policies | History | Lineage | Insights | Quality

Description

The table contains data on the market share of imported commodities grouped by sector and country. It includes information on the year of the transaction, the sector classification, the originating country, and various financial metrics related to the imports. Possible use cases include analyzing import trends by sector and country, assessing market share fluctuations over time, and evaluating the impact of imports on specific sectors.

Filter columns...

Column	Type	Popularity	Comment	Tags	Column masking
co_ano	int	High	Year of the import transaction		
setor_capitulo	string	High	Classification category for commodities, grouping imports into specific sectors.		
co_pais	int	High	Country of origin for the imported commodities, indicating where the goods are sourced from.		
vl_fob_pais_setor	double	High	Represents the Free on Board (FOB) value of imported commodities from a specific country within a particular sector.		
vl_fob_total_setor	double	High	Total Free on Board (FOB) value of imported commodities within a specific sector.		
market_share_perc	double	High	Percentage representing the market share of imported commodities from a specific country within a particular sector.		

4. Pipeline de Qualidade de Dados

Durante a esteira ETL (Bronze → Silver), foram resolvidos os seguintes problemas estruturais:

- **Completeness e Validade Financeira:** Foram identificados registros brutos com valores zerados ou negativos. O filtro na criação da camada Silver ($AND\ VL_FOB > 0$) garantiu que apenas transações reais entrassem na base de cálculo de mercado

```
CAST(KG_LIQUIDO AS DOUBLE) AS kg_liquido,  
CAST(VL_FOB AS DOUBLE) AS vl_fob  
FROM mvp.bronze.comex_importacao_total  
WHERE CO_ANO IS NOT NULL  
AND CO_PAIS IS NOT NULL  
AND VL_FOB > 0;
```

- **Consistência de Chaves:** Alguns códigos NCM antigos vinham formatados com comprimentos variáveis. A aplicação da função `LPAD(..., 8, '0')` estabilizou a coluna, o que foi crítico para a precisão da função `SUBSTR` ao gerar o `setor_capitulo` macroeconômico.

```
LPAD(CAST(CO_NCM AS STRING), 8, '0') AS co_ncm,  
  
SUBSTR(LPAD(CAST(CO_NCM AS STRING), 8, '0'), 1, 2) AS setor_capitulo,  
CAST(CO_PAIS AS INT) AS co_pais,  
UPPER(TRIM(SG_UF_NCM)) AS sg_uf_ncm,
```

5. Análise de Dados e Solução de Negócio

Após a consolidação da tabela analítica na camada Gold, o pipeline avança para a camada final de visualização e extração de valor: o notebook de Análises (MVP06_Analise). Através de consultas SQL otimizadas sobre a tabela `gold_market_share_setor_pais`, foram extraídas as respostas definitivas para o problema de negócio proposto.

5.1 Pergunta 1: Quais países mais ganharam ou perderam espaço relativo (*market share* em Valor FOB) entre 1997 e o período recente?

A comparação dos extremos da série histórica demonstrou uma forte reconfiguração na geopolítica de fornecimento do Brasil.

- **Os Maiores Ganhadores:** A **China (República Popular - 160)** consagrou-se como o maior expoente absoluto, saltando de meros 1.91% das importações totais em 1997 para **26.37%** no período recente (um impressionante ganho de **+24.45 pontos percentuais**). Outros emergentes também avançaram, como a Federação da Rússia (+3.13 pp) e a Índia (+2.28 pp).
- **Os Maiores Perdedores Relativos:** Potências tradicionais ocidentais e sul-americanas sofreram forte retração no espaço relativo. A **Argentina (63)** caiu de 13.09% para 4.42% (-8.66 pp), e os **Estados Unidos (249)** — antigo líder hegemônico — recuou de 22.57% para 13.97% (-8.60 pp). Quedas proporcionais também foram vistas no Japão (-3.83 pp) e na Alemanha (-3.00 pp).

Evidência do Script e Resultados da Análise Global (Ganhadores/Perdedores):

```
%sql
USE CATALOG mvp;
USE SCHEMA gold;

WITH importacoes_pais_geral AS (
    SELECT
        co_ano,
        co_pais,
        SUM(vl_fob_pais_setor) AS vl_fob_pais_ano
    FROM gold_market_share_setor_pais
    GROUP BY co_ano, co_pais
),
total_brasil_ano AS (
    SELECT
        co_ano,
        SUM(vl_fob_pais_setor) AS vl_fob_total_brasil
    FROM gold_market_share_setor_pais
    GROUP BY co_ano
),
market_share_global AS (
    SELECT
        p.co_ano,
        p.co_pais,
        (p.vl_fob_pais_ano / t.vl_fob_total_brasil) * 100 AS ms_global_perc
    FROM importacoes_pais_geral p
    JOIN total_brasil_ano t ON p.co_ano = t.co_ano
),
inicio AS (
    SELECT co_pais, ms_global_perc AS ms_1997
    FROM market_share_global
    WHERE co_ano = 1997
),
fim AS (
    SELECT co_pais, ms_global_perc AS ms_recente, co_ano AS ano_recente
    FROM market_share_global
    WHERE co_ano = (SELECT MAX(co_ano) FROM market_share_global)
)
SELECT
    f.ano_recente,
    i.co_pais,
    ROUND(i.ms_1997, 2) AS market_share_1997_perc,
    ROUND(f.ms_recente, 2) AS market_share_recente_perc,
    ROUND((f.ms_recente - i.ms_1997), 2) AS variacao_pontos_percentuais
FROM inicio i
JOIN fim f ON i.co_pais = f.co_pais
ORDER BY variacao_pontos_percentuais DESC;
```

5.2 Pergunta 2: Como essa realocação se distribui por grandes setores da economia (Capítulos NCM)?

Desagregando as importações pelos Capítulos do Sistema Harmonizado (setor_capitulo), notou-se que a disrupção se concentrou majoritariamente no polo industrial.

- **Tecnologia e Bens de Capital:** Em setores de alta intensidade (como os Capítulos 84 e 85 — Máquinas, Reatores e Material Elétrico), os eixos norte-americano e europeu perderam a liderança isolada para a Ásia, consolidando a China como a fábrica do mundo e principal provedora de maquinário e eletrônicos para o Brasil.
- **Química e Indústria de Base:** Nos capítulos de polímeros e plásticos (Cap. 39), a transição de rotas logísticas foi severa, embora o mercado europeu tenha mantido posições resilientes em setores de altíssimo valor agregado (como produtos farmacêuticos).
- **Commodities:** Setores ligados ao agronegócio primário e minerais (ex: Cap. 27) mantiveram fluxos mais concentrados no Mercosul e na América do Norte, demonstrando resiliência às mudanças asiáticas.

Evidência do Script e Resultados Setoriais (De-Para de Líderes):

```
▶ Yesterday (4s) 4

%sql
USE CATALOG mvp;
USE SCHEMA gold;

WITH ranked_1997 AS (
  SELECT
    setor_capitulo,
    co_pais AS pais_1997,
    market_share_perc AS ms_1997,
    ROW_NUMBER() OVER(PARTITION BY setor_capitulo ORDER BY market_share_perc DESC) as rn
  FROM gold_market_share_setor_pais
  WHERE co_ano = 1997
),
ranked_recente AS (
  SELECT
    setor_capitulo,
    co_pais AS pais_recente,
    market_share_perc AS ms_recente,
    ROW_NUMBER() OVER(PARTITION BY setor_capitulo ORDER BY market_share_perc DESC) as rn
  FROM gold_market_share_setor_pais
  WHERE co_ano = (SELECT MAX(co_ano) FROM gold_market_share_setor_pais)
)
SELECT
  r97.setor_capitulo,
  r97.pais_1997 AS maior_fornecedor_1997,
  ROUND(r97.ms_1997, 2) AS ms_1997_perc,
  rr.pais_recente AS maior_fornecedor_recente,
  ROUND(rr.ms_recente, 2) AS ms_recente_perc
FROM ranked_1997 r97
JOIN ranked_recente rr
  ON r97.setor_capitulo = rr.setor_capitulo
  AND r97.rn = 1 AND rr.rn = 1
ORDER BY r97.setor_capitulo;
```

5.3 Pergunta 3: Quais classes de produtos (NCMs) apresentaram maior volatilidade ou mudança estrutural na origem?

Avaliando a amplitude matemática ($\text{amplitude_volatilidade_lider}$) entre a participação máxima e mínima do país líder em cada setor, identificamos os mercados mais instáveis da série.

- **Altíssima Volatilidade:** Setores como os Capítulos 66 (Guarda-chuvas e artefatos), 50 (Seda), 67 (Penas e penugens) e 60 (Tecidos de malha) registraram uma volatilidade assustadora, variando entre 94 e 98 pontos percentuais de amplitude.
- **Conclusão:** Isso comprova que mercados ligados ao setor têxtil, vestuário e artefatos industriais leves sofreram rupturas brutais com a globalização. Foram setores que transitaram de mercados internamente monopolizados (ou dependentes de um único parceiro ocidental) para um domínio integral e voraz por parte de novos parceiros asiáticos ao longo destas quase três décadas.

Evidência do Script e Resultados de Volatilidade de Mercado:

```
%sql
USE CATALOG mvp;
USE SCHEMA gold;

SELECT
    setor_capitulo,
    MAX(market_share_perc) AS max_ms_historico,
    MIN(market_share_perc) AS min_ms_historico,
    ROUND((MAX(market_share_perc) - MIN(market_share_perc)), 2) AS amplitude_volatilidade_lider
FROM gold_market_share_setor_pais
GROUP BY setor_capitulo
ORDER BY amplitude_volatilidade_lider DESC
LIMIT 15;
```

6. Considerações Finais e Autoavaliação

6.1 Atingimento dos Objetivos Propostos

O projeto atingiu com êxito o objetivo central de desenhar, implementar e validar um *pipeline* analítico de Engenharia de Dados de ponta a ponta em ambiente *Cloud* (Databricks). Ao processar uma série histórica massiva (30 anos de registros de importação do MDIC), o *pipeline* transcendeu o simples transporte de dados, entregando uma solução arquitetural baseada em Lakehouse (padrão Medalhão). Através da camada analítica (Gold), o projeto respondeu de forma objetiva, mensurável e em tempo de execução às três complexas perguntas macroeconômicas formuladas no escopo inicial do negócio, comprovando a eficácia da modelagem desenvolvida.

6.2 Desafios Técnicos e Dificuldades Encontradas

Durante a construção do MVP, alguns desafios intrínsecos ao processamento de Big Data precisaram ser superados:

- **Volumetria e Escalabilidade Temporal:** Lidar com dezenas de ficheiros anuais contendo milhões de linhas (1997 a 2026) exigiu atenção especial na camada de leitura (Bronze). O uso da função distribuída `read_files` e do formato Delta Lake foi crucial para evitar gargalos de I/O (leitura e escrita em disco).

- **Consistência de Dados Históricos:** Como os dados abrangem três décadas, os padrões de preenchimento e tipagem mudaram ao longo do tempo. O desafio de padronizar códigos NCM para exatos 8 dígitos (via a função LPAD) e remover registros ruidosos na camada Silver evidenciou a importância crítica de processos rigorosos de Qualidade de Dados (Data Quality) antes de qualquer modelagem financeira.
- **Performance de Agregação:** O cálculo matemático do *market share* exigia dividir o universo da importação em partições anuais e setoriais (através de *Common Table Expressions* - CTEs). Garantir que o motor Spark executasse essas agregações cruzadas de forma performática exigiu *queries* estruturadas e limpas na Camada Gold.

6.3 Pontos de Melhoria e Visão de Futuro (Próximos Passos)

Apesar do sucesso do MVP, a solução desenhada abre portas para aprimoramentos técnicos futuros num cenário de produção industrial:

1. **Modelagem Dimensional Rigorosa:** Atualmente, os dados estão denormalizados num formato essencialmente plano na Gold. Um passo de evolução seria a implementação formal de um *Star Schema* ou *Snowflake*, criando tabelas dimensão isoladas oficiais (*dim_pais*, *dim_setor_ncm*, *dim_tempo*) cruzadas com uma tabela fato central (*fato_importacao*).
2. **Enriquecimento Semântico Automatizado:** Integração de uma rotina no *pipeline* que converta dinamicamente os códigos NCM e numéricos de país nas respectivas descrições textuais (usando as tabelas oficiais de domínio do MDIC), de forma que a saída da Gold seja 100% amigável ao utilizador final, sem necessitar de cruzamentos manuais nas análises.
3. **Data Visualization (BI):** Conectar de forma direta a tabela Gold a uma ferramenta de *Business Intelligence* ou utilizar o Databricks SQL Dashboards para construir painéis interativos de consumo gerencial em tempo real, mitigando a dependência do ambiente de *notebooks* para visualização.
4. **Orquestração Automatizada:** Substituir a execução manual dos *notebooks* pela criação de um fluxo de orquestração via *Databricks Workflows* (Jobs), programando o *pipeline* para atualizar automaticamente sempre que um novo ficheiro anual CSV for depositado no volume do catálogo (Staging).

6.4 Conclusão Pessoal (Autoavaliação)

A elaboração deste MVP permitiu vivenciar de forma muito concreta o quotidiano e as decisões técnicas inerentes ao trabalho de um Engenheiro de Dados. Ficou claro que o sucesso da visualização final não reside apenas no algoritmo analítico, mas predominantemente no rigor, limpeza e arquitetura robusta definidos na base (nas camadas Bronze e Silver). A experiência na adoção de um *Data Lakehouse*, combinando a flexibilidade do *Data Lake* com a governança transacional dos padrões de um *Data Warehouse* (graças ao Delta Lake), consolidou não só as *hard skills* de manipulação e orquestração na nuvem, mas também o raciocínio crítico focado na entrega de valor.